

회귀분석

Term Project

최종 보고서



[프로젝트 주제]

고객 특성 분석을 통한 소비 패턴
이해 및 마케팅 인사이트 도출

응용통계학과
202111870
서민석

목차

1. 서론	3
1.1. 프로젝트 개요	
2. 데이터 요약 및 설명	3
2.1. 데이터 개요 및 구조	
2.2. 변수 정의 및 전처리	
2.3. 주요 변수별 기초 통계량과 분포	
3. 회귀 모델 구축	6
3.1. 모델링 전략 및 변수 변환	
3.2. 모델 구축 및 요약	
4. 모델 진단 및 평가	7
4.1. 모델 진단	
4.2. 모델 개선	
4.3. 최종 모델 선정	
5. 결론	9
5.1. 최종 결론	
5.2. 분석의 한계점	
부록(Appendix)	11

1. 서론

1.1. 프로젝트 개요

오늘날 마케팅 분야에서 고객 데이터 분석은 기업의 경쟁력 확보를 위한 핵심 요소이다. 특히 고객의 구매 행동을 이해하고 소비 패턴을 분석하는 것은 효과적인 마케팅 전략 수립과 매출 증대에 중요한 역할을 한다. 본 프로젝트는 마케팅 캠페인 데이터를 활용하여 고객의 인구통계학적 특성(나이, 소득, 교육 수준 등)과 과거 구매 행동(최근 구매일, 총 캠페인 수락 횟수 등)이 총 소비액에 미치는 영향을 분석하고, ‘고객의 어떤 특성이 높은 소비로 이어지는가?’라는 주요 연구 질문에 답하고자 한다.

본 연구의 핵심 목표는 고객의 총 소비액에 유의미한 영향을 미치는 요인들을 식별하고, 각 변수의 영향력과 방향성을 파악하는 것이다. 이를 통해 기업이 고객 특성을 보다 효과적으로 이해하고 잠재적 고가치 고객을 식별하여, 고객 맞춤형 마케팅 전략 수립과 데이터 기반 의사결정에 활용할 수 있는 인사이트를 제공하고자 한다.

2. 데이터 요약 및 설명

2.1. 데이터 개요 및 구조

본 프로젝트에서는 Kaggle의 “Marketing Campaign” 데이터셋을 활용하여 분석을 진행하였다. 해당 데이터셋은 고객의 인구통계학적 특성, 구매 이력 및 마케팅 캠페인 반응 정보를 포함하고 있으며, 고객 소비 행동을 분석하기 위해 활용하였다.

2.2. 변수 정의 및 전처리

본 분석에 사용된 주요 변수들은 고객의 특성 분석을 목표로 정의되었으며, 분석 목적에 맞게 여러 원시 변수를 통합, 재구성하여 파생변수를 생성함으로써 고객 특성을 보다 효과적으로 반영하고자 하였다.

- Total_Spending(총 소비액): 6개 제품 카테고리의 소비액을 합산하여 생성한 변수로, 고객의 전체 소비 규모를 나타내며 본 연구의 종속변수로 활용하였다.
- Income(소득): 고객의 연간 가구 소득을 나타내는 변수(수치형)로, 고객의 구매력을 설명하는 주요 변수이다. 24건의 결측치가 존재하여 중앙값으로 대체하는 전처리 진행

- Age(나이): 고객의 연령을 나타내는 변수(수치형)로, 연령에 따른 소비 패턴 차이를 확인하기 위해 활용하였다. Year_Birth 변수에 현재 연도를 반영하여 Age 생성. 100세 이상의 자료가 3건으로 이는 총 소비와 크게 관련 없을 것으로 판단하여 제거하도록 함.
- Education(교육수준): 고객의 교육수준(범주형: Graduation, PhD, Master, 2n Cycle, Basic)
- Marital_Status(결혼 여부): 고객의 결혼 상태(범주형: Single, Married, Together 등), Absurd, YOLO는 의미가 불분명한 범주이므로 삭제하고 Alone은 Single과 동일한 의미로 판단하여 통합하였다.
- TotalChildren(총 자녀수): 고객 가정의 전체 자녀 수(수치형), Kidhome과 Teenhome 변수를 합산하여 파생변수 TotalChildren 생성
- Recency(최근 구매일): 고객의 마지막 제품 구매로부터 지난 일수(수치형)로, 고객 활성도를 파악하기 위해 활용하였다.
- NumWebVisitsMonth(월간 웹사이트 방문 횟수): 고객의 온라인 서비스 이용 수준을 나타내는 변수이다.(수치형)
- TotalCampaignsAccepted(총 수락 캠페인 수): 고객이 마케팅 캠페인에 참여한 횟수(수치형), 과거 5개의 캠페인 수락 여부를 나타내는 변수(AcceptedCmp~AcceptedCmp5)와 최근 캠페인 수락여부를 나타낸 Response 변수를 합산하여 생성

2.3. 주요 변수별 기초통계량과 분포

분석에 사용된 “Marketing Campaign” 데이터셋을 marketing_df로 불러온 후 파생변수 생성과 결측치 처리 등의 전처리 결과, 총 2233개의 관측치와 33개의 변수로 구성되어 있다.

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
Total_Spending	5.0	69.0	396.0	605.4	1044.0	2525.0
Income	1730	35441	51382	52213	68281	666666
Age	29.00	48.00	55.00	56.11	66.00	85.00
TotalChildren	0.00	0.00	1.00	0.9516	1.00	3.00
Recency	0.00	24.00	49.00	49.14	74.00	99.00
TotalCampaign Accepted	0.00	0.00	0.00	0.446	1.00	5.00

- Total_Spending: 일반적으로 낮은 금액대에 많은 고객이 분포하고 고액 소비 고객은 소수인 오른쪽으로 강하게 치우친 양의 왜도 분포를 보였다. 이는 소수의 고액 소비자가 존재하며, 분석의 안정성을 위해 로그 변환의

필요성을 시사함.

- Income: Total_Spending과 유사하게 오른쪽으로 크게 치우친 분포를 보였으며, 특히 상위 소득층에 극단적인 고소득자(이상치)가 일부 존재하였다. 이는 소득이 소비에 미치는 영향력이 클 것으로 예상되는 동시에, 해당 이상치의 영향을 면밀히 검토할 필요성을 제기함.
- Age: 고객의 연령 분포는 비교적 고르게 분포하여 일반적인 인구 연령 분포와 유사한 특성을 나타냄.
- Recency: 최근 구매 고객의 비중이 상대적으로 높게 나타났으며, 고객의 구매 시점에 차이가 존재함을 확인할 수 있었다.
- NumWebVisitsMonth: 주로 낮은 횟수(2~7회)에 고객이 집중되어 있고 방문 횟수가 많아질수록 고객 수는 감소하는 형태를 보임.
- TotalCampaignsAccepted: 대부분의 고객이 0~1회 캠페인을 수락한 반면, 소수의 고객은 여러 캠페인에 반복적으로 참여한 분포를 보임.
- TotalChildren: 0명, 1명, 2명에 고객이 집중되는 이산형 분포를 나타냄.
- Education & Marital_Status: 교육 수준과 결혼 여부는 고객 집단의 특성을 파악하고 소비 패턴의 차이를 분석하기 위한 범주형 변수로 활용하였다.

※ 각 변수별 분포 플롯은 부록 참고

3. 회귀 모델 구축

3.1. 모델링 전략 및 변수 변환

본 프로젝트에서는 고객의 총 소비액에 영향을 미치는 요인들을 파악하고자 다중 선형 회귀 모델을 구축한다. 모델의 통계적 가정을 충족하고 설명력을 높이기 위해, 변수 변환을 수행한다. 종속 변수(Total_Spending)는 강한 양의 왜도를 보이는 것으로 확인되었기에 Log_Total_Spending이라는 로그변환을 적용한 새로운 종속변수를 사용하였다.

3.2. 모델 구축 및 요약

Log_Total_Spending을 종속변수로 한 모델을 작성하였다.

```
Call:
lm(formula = Log_Total_Spending ~ Income + age + Education +
    Marital_Status + Recency + NumWebVisitsMonth + TotalCampaignsAccepted +
    TotalChildren, data = marketing_df)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-19.0761  -0.5747   0.1230   0.6838   3.3702
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.689e+00  1.748e-01  21.100 < 2e-16 ***
Income       2.912e-05  1.092e-06  26.667 < 2e-16 ***
age          1.290e-02  1.963e-03   6.575 6.07e-11 ***
EducationBasic -4.847e-01  1.584e-01  -3.060 0.00224 **
EducationGraduation  8.898e-02  7.823e-02   1.137 0.25550
EducationMaster  8.612e-02  8.993e-02   0.958 0.33835
EducationPhD     6.848e-02  8.667e-02   0.790 0.42955
Marital_StatusMarried  8.267e-02  7.556e-02   1.094 0.27406
Marital_StatusSingle  3.454e-02  8.207e-02   0.421 0.67387
Marital_StatusTogether  2.479e-02  7.925e-02   0.313 0.75441
Marital_StatusWidow   1.191e-01  1.347e-01   0.884 0.37697
Recency        1.770e-03  7.470e-04   2.369 0.01791 *
NumWebVisitsMonth -3.202e-02  1.134e-02  -2.825 0.00478 **
TotalCampaignsAccepted  2.370e-01  2.600e-02   9.116 < 2e-16 ***
TotalChildren  -4.824e-01  3.297e-02 -14.629 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1.016 on 2218 degrees of freedom
Multiple R-squared:  0.5341,    Adjusted R-squared:  0.5312
F-statistic: 181.6 on 14 and 2218 DF,  p-value: < 2.2e-16
```

위 모델이 총 변동의 약 53%를 설명하고 있으며, F-통계량을 통해 모델이 통계적으로 유의미하다고 볼 수 있으나, 개별 예측 변수는 유의미하지 않은 변수가 있음이 확인된다.

4. 모델 진단 및 평가

4.1. 모델 진단

1) 다중공선성

R을 이용하여 모델의 다중공선성을 조사한 결과, 모든 변수에 대해 VIF값이 2 이하이므로 독립변수들 간에 심각한 다중공선성 문제는 없는 것으로 판단된다. 이전 분석에서 결혼여부와 나이, 자녀 수 변수 간에 다중공선성이 의심되었으나 심각한 수준이 아님이 나타났다.

2) 진단 플롯

- Residual vs Fitted: 빨간색 Lowess 선이 곡선 패턴을 보이며 0에서 벗어나 비선형 가능성 및 잔차의 등분산성 위반 가능성을 시사함
- Normal Q-Q: 대부분의 점들이 점선을 따르지만, 왼쪽 아래 꼬리 부분에서 점점으로부터 크게 벗어남이 관찰되며, 이는 잔차 분포가 정규분포를 따르지 않을 가능성을 시사함
- Scale-Location: Lowess선이 우상향하는 경향을 보이며 잔차의 분산이 증가하는 패턴이 관찰됨. 이는 등분산성 위반을 의미함
- Residual vs Leverage: 2227번 관측치가 높은 레버리지와 큰 음의 잔차를 가지고 있어 강력한 영향점임을 시사함

종합적으로 현재의 모델은 다중공선성 문제는 발견되지 않았으나, 잔차 진단 결과 선형성, 등분산성, 정규성 가정이 충분히 충족되지 않는 것으로 나타났다. 또한 2227번 관측치와 같은 강력한 영향점이 존재함이 확인되어 모형 개선의 필요성이 제기되었다.


4.2. 모델 개선

초기 모델 진단 결과, 2227번 관측치가 강력한 영향점으로 나타나 회귀 가정을 위반하는데 큰 영향을 미쳤을 것이라 예측된다.

2227번 관측치는 Income이 666,666으로 데이터셋 내에서 극단적으로 높은 값을 가짐에도 불구하고 Total_Spending은 상대적으로 낮은 수준을 보여 모델의 예측 경향성에서 크게 벗어난다. 이는 일반적인 고객의 소비 패턴을 대표한다고 보기 어려운 이상 관측치라 판단하였다. 따라서 2227번 관측치를 제거함으로써 안정성과 신뢰성을 확보하고, 보다 일반화된 고객 소비 패턴을 반영하는 모델을 구축하고자 하였다.

2227번 관측치를 제거한 후 진단 플롯을 재확인한 결과 각 플롯들이 이전에

비해 크게 개선된 모습을 보였으며, 극단적인 이탈을 보이지 않기에 회귀모형의 주요 가정이 전반적으로 개선된 것으로 판단하였다.



영향점에 대한 추가적인 판단을 위해 Cook's Distance를 확인한 결과, 일반적인 기준값인 $4/n$ 을 초과하는 관측치들이 일부 있었으나, 2227번 관측치처럼 모델에 심각한 왜곡을 줄 정도의 강력한 영향점은 아니라고 판단하였다. 이들을 모두 제거하는 것은 데이터의 과도한 손실로 모델의 일반화 능력을 해칠 수 있기에 추가적인 제거는 진행하지 않았다.

이와 같은 모델 개선 과정을 통해 다중 선형 회귀 분석의 주요 가정을 보다 합리적으로 만족하는 모델의 기반을 마련하였다. 또한 이 과정에서 모델의 Adjusted R-squared 값이 0.5312에서 0.6661로 향상되었음을 확인하였다.

4.3. 최종 모델 선정

앞선 모델 개선을 통해 구축된 `lm_model_cleaned` 모델의 `summary()` 결과를 살펴보면 Education과 Marital_Status라는 두 범주형 변수의 모든 더미 변수가 통계적으로 유의미하지 않음이 확인되었다. 모델의 간결성을 높이고 해석의 명확성을 확보하기 위해, 이러한 통계적으로 유의미하지 않은 변수들을 제거하는 추가적인 모델 재정의의를 시도하였다.

이를 위해 Marital_Status 변수만 제거한 모델(`lm_model_s1`)과 Education 변수만 제거한 모델(`lm_model_s2`), 두 변수 모두 제거한 모델(`lm_model_s3`) 총 3가지 후보 모델을 구축하고 그 성능을 비교하였다.

기존 모델을 포함한 각 모델의 `summary()` 결과 Adjusted R-squared 값은 4가지 모델 모두 0.6661 내외의 유사한 설명력을 보였다. 특히 s3 모델에서는 모델의 설명력을 유지하면서도 모든 변수가 통계적으로 유의하게 나타난 가장 간결한 모델을 구성하였다.

종합적으로 판단할 때, lm_model_s3는 모델 가정을 합리적으로 만족시키면서도 최적의 설명력과 간결성, 모든 예측 변수의 통계적 유의미성을 확보한 가장 적합한 최종 모델이라고 결론 내릴 수 있다.

```
> summary(lm_model_s3)
```

```
Call:
lm(formula = Log_Total_Spending ~ Income + age + Recency + NumWebVisitsMonth +
    TotalCampaignsAccepted + TotalChildren, data = marketing_df_cleaned)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-9.2665 -0.4499  0.1086  0.5563  5.0358
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.261e+00  1.322e-01  17.103 < 2e-16 ***
Income       5.383e-05  1.204e-06  44.702 < 2e-16 ***
age          7.080e-03  1.612e-03   4.393 1.17e-05 ***
Recency      1.175e-03  6.301e-04   1.864 0.062417 .
NumWebVisitsMonth 8.960e-02  1.038e-02   8.632 < 2e-16 ***
TotalCampaignsAccepted 8.404e-02  2.246e-02   3.742 0.000187 ***
TotalChildren -4.370e-01  2.763e-02 -15.819 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.8573 on 2225 degrees of freedom
Multiple R-squared:  0.667,    Adjusted R-squared:  0.6661
F-statistic: 742.8 on 6 and 2225 DF, p-value: < 2.2e-16
```

```
> lm.beta(lm_model_s3)
```

```
Call:
lm(formula = Log_Total_Spending ~ Income + age + Recency + NumWebVisitsMonth +
    TotalCampaignsAccepted + TotalChildren, data = marketing_df_cleaned)
```

```
Standardized Coefficients::
              (Intercept)              Income              age              Recency
              NA              0.77717448              0.05582738              0.02292044
NumWebVisitsMonth TotalCampaignsAccepted TotalChildren
0.14645232              0.05041549              -0.22159788
```

5. 결론

5.1. 최종 결론

본 연구에서는 고객의 총 소비액(Total_Spending)에 영향을 미치는 요인을 파악하고, 이를 바탕으로 고객 소비 패턴을 이해하여 데이터 기반 마케팅 의사 결정에 활용할 수 있는 인사이트를 도출하고자 다중선형 회귀분석을 수행하였다. 초기 모델 진단에서 확인된 영향점과 회귀 가정 위반을 개선하고 통계적으로 유의하지 않은 변수를 제거하는 과정을 거쳐 최종 회귀모형(lm_model_s3)을 구축하였다.

추정된 회귀식은 다음과 같다.

$$\text{Log_Total_Spending} = 2.261 + (0.00005383 \times \text{Income}) + (0.00708 \times \text{Age}) + (0.001175 \times \text{Recency}) + (0.08960 \times \text{NumWebVisitsMonth}) + (0.08404 \times \text{TotalCampaignsAccepted}) - (0.4370 \times \text{TotalChildren})$$

최종 모델은 Log_Total_Spending을 종속변수로, Income, Age, Recency, NumWebVisitsMonth, TotalCampaignsAccepted, TotalChildren을 독립변수로 포함하였다. Adjusted R-squared는 0.6661로 비교적 높은 설명력을 보였으며, 최종 모형에 포함된 모든 변수는 통계적으로 유의하였다. 또한 모델 진단 결과 회귀분석의 주요 가정을 이전보다 합리적으로 충족하여 최종 모델의 해석 가능성과 신뢰성을 확보하였다.

최종 모델을 통해 도출된 주요 결론 및 시사점은 다음과 같다.

분석 결과, 소득(Income)은 1달러 당의 효과에 대한 계수라 절댓값이 작으나, 표준화 계수가 0.78로 고객의 총 소비액에 가장 영향력이 큰 변수로 확인되었다. 소득이 높은 고객일수록 소비 규모가 증가하는 경향을 보였으며, 이는 고객의 구매력이 소비 행동에 직접적인 영향을 미친다는 점을 시사한다. 따라서 기업은 소득 수준이 높은 고객군을 핵심 고객군으로 관리하거나 프리미엄 상품 및 맞춤형 프로모션을 우선적으로 제공하는 전략을 고려할 수 있다.

또한 캠페인 수락 횟수(TotalCampaignsAccepted)는 총 소비액과 유의한 양(+)의 관계를 보였다. 이는 과거 마케팅 캠페인에 적극적으로 반응한 고객일수록 소비 규모가 큰 경향이 있음을 의미하며, 향후 프로모션이나 이벤트 대상 고객을 선정하는 기준으로 활용할 가능성을 보여준다.

웹사이트 방문 횟수(NumWebVisitsMonth) 역시 다른 변수의 영향을 통제한 회귀모형에서는 총 소비액과 유의한 양(+)의 관계를 보였다. 즉 동일한 조건에서는 웹사이트를 자주 방문하는 고객일수록 소비 규모가 증가하는 경향이 있음을 의미한다. 이는 실제 마케팅 현장에서 웹사이트 이용 행동이 활발한 고객을 식별하고 우선 관리 대상 고객군을 선정하여 타겟 마케팅을 진행하는 기준으로 활용될 수 있다. 한편, 평균 소비액을 단순 시각화한 결과에서는 웹사이트 방문 횟수가 증가할수록 평균 소비액이 감소하는 경향이 관찰되었다. 이는 소득과 같은 강한 설명변수의 영향이 함께 반영된 결과로 해석된다. 따라서 해당 변수는 단순 방문량보다 고객의 특성과 함께 해석해야 하는 변수이며, 웹사이트를 자주 방문하지만 구매로 이어지지 않는 고객군이 존재할 가능성도 고려하여 구매 전환을 유도하는 리마케팅 전략이 유효할 것이다.

예외적으로 양(+)의 관계인 Recency는 10% 유의수준에서만 통계적으로 유의한 결과를 보였으므로 해석에 주의가 필요하다. 이는 데이터 특성이나 고객군의 특수성이 반영된 결과일 가능성이 있으며, 추가적인 고객 세분화 분석을 통

해 원인을 확인할 필요가 있다. 다만 최근 구매 경과일이 긴 고객을 대상으로는 재방문과 구매 전환을 유도할 수 있는 리텐션 프로모션 전략을 고려할 수 있다.

반면 TotalChildren은 총 소비액과 음(-)의 관계를 나타냈다. 이는 자녀 양육에 따른 지출 분산 등으로 인해 해당 플랫폼에서의 소비 규모가 감소하는 경향을 보였다.

종합하면 본 연구는 고객의 인구통계학적 특성이나 구매 행동 데이터만으로도 총 소비액을 상당 부분 설명할 수 있음을 확인하였다. 이러한 결과는 고객 세분화, 마케팅 대상 고객 선정, 맞춤형 프로모션 기획 등 다양한 데이터 기반 의사결정에 활용될 수 있다.

5.2. 분석의 한계점

본 연구는 고객의 총 소비액에 영향을 미치는 주요 요인을 분석하고 설명력 있는 회귀모형을 구축하였으나, 다음과 같은 한계가 존재한다.

1) 데이터의 범위에 대한 한계: 본 연구는 제공된 Marketing Campaign 데이터셋을 기반으로 분석을 수행하였으며, 고객의 직업이나 지역, 구매채널 등 소비에 영향을 줄 수 있는 다양한 요인을 포함하지 못했다. 따라서 고객의 소비 행동을 완전히 설명하기에는 한계가 있으며 모델이 설명하지 못하는 변동이 존재할 수 있다.


2) 회귀모형의 구조적 한계: 본 연구에서는 변수와 소비액 간의 선형적인 관계를 가정했으며, 독립변수 간 상호작용 효과는 고려하지 않았다. 실제로는 소득과 연령, 가족 구성 등 여러 요인이 복합적으로 작용하여 소비 행동에 영향을 미칠 가능성이 크므로 이러한 관계를 충분히 반영하지 못했을 수 있다.





향후 연구에서는 다양한 고객 특성 변수를 추가하고 상호작용 효과를 고려한 모델이나 트리 기반 모델 등 다른 분석 기법과의 성능을 비교한다면 더욱 높은 예측력을 확보할 수 있을 것으로 기대된다. 또한 본 연구에서 도출한 마케팅 활용 방안은 데이터 분석 결과를 바탕으로 제안한 것이므로 실제 서비스 환경에서는 A/B 테스트와 같은 실험을 통해 전략의 효과를 검증하는 과정이 추가적으로 필요할 것으로 보인다.







부록(Appendix)

2. 데이터 요약 및 설명

-각 변수 별 플롯








4. 모델 진단 및 평가

-다중공선성 결과물

> print(vif_values)


	GVIF	Df	GVIF ^{1/(2*Df)}
Income	1.619415	1	1.272562
age	1.139870	1	1.067647
Education	1.113066	4	1.013480
Marital_Status	1.065057	4	1.007910
Recency	1.011264	1	1.005616
NumWebVisitsMonth	1.633594	1	1.278121
TotalCampaignsAccepted	1.157474	1	1.075859
TotalChildren	1.330311	1	1.153391

-초기 진단플롯



-Cook's Distance

Cooks distance for lm_model_cleaned



-summary(lm_model_cleaned)

```
> summary(lm_model_cleaned)
```

Call:

```
lm(formula = Log_Total_Spending ~ Income + age + Education +  
    Marital_Status + Recency + NumWebVisitsMonth + TotalCampaignsAccepted +  
    TotalChildren, data = marketing_df_cleaned)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.2145	-0.4635	0.1035	0.5546	5.0014

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.156e+00	1.562e-01	13.803	< 2e-16	***
Income	5.391e-05	1.239e-06	43.519	< 2e-16	***
age	7.170e-03	1.667e-03	4.300	1.78e-05	***
EducationBasic	-3.421e-02	1.345e-01	-0.254	0.799267	
EducationGraduation	4.409e-02	6.604e-02	0.668	0.504436	
EducationMaster	2.910e-02	7.592e-02	0.383	0.701575	
EducationPhD	-5.430e-02	7.326e-02	-0.741	0.458721	
Marital_StatusMarried	8.866e-02	6.377e-02	1.390	0.164629	
Marital_StatusSingle	6.854e-02	6.928e-02	0.989	0.322563	
Marital_StatusTogether	7.092e-02	6.690e-02	1.060	0.289260	
Marital_StatusWidow	1.787e-01	1.137e-01	1.571	0.116340	
Recency	1.166e-03	6.308e-04	1.848	0.064751	.
NumWebVisitsMonth	9.074e-02	1.041e-02	8.718	< 2e-16	***
TotalCampaignsAccepted	8.557e-02	2.251e-02	3.801	0.000148	***
TotalChildren	-4.356e-01	2.787e-02	-15.630	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8574 on 2217 degrees of freedom

Multiple R-squared: 0.6681, Adjusted R-squared: 0.6661

F-statistic: 318.8 on 14 and 2217 DF, p-value: < 2.2e-16

-summary(lm_model_sl)

```
> summary(lm_model_sl)
```

Call:

```
lm(formula = Log_Total_Spending ~ Income + age + Education +  
    Recency + NumWebVisitsMonth + TotalCampaignsAccepted + TotalChildren,  
    data = marketing_df_cleaned)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.2309	-0.4611	0.1125	0.5556	5.0144

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.227e+00	1.423e-01	15.653	< 2e-16	***
Income	5.387e-05	1.238e-06	43.530	< 2e-16	***
age	7.308e-03	1.631e-03	4.481	7.81e-06	***
EducationBasic	-2.923e-02	1.343e-01	-0.218	0.827789	
EducationGraduation	4.431e-02	6.597e-02	0.672	0.501837	
EducationMaster	2.934e-02	7.586e-02	0.387	0.699005	
EducationPhD	-5.223e-02	7.318e-02	-0.714	0.475448	
Recency	1.156e-03	6.304e-04	1.833	0.066874	.
NumWebVisitsMonth	9.026e-02	1.040e-02	8.681	< 2e-16	***
TotalCampaignsAccepted	8.544e-02	2.247e-02	3.802	0.000147	***
TotalChildren	-4.365e-01	2.784e-02	-15.680	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8572 on 2221 degrees of freedom

Multiple R-squared: 0.6677, Adjusted R-squared: 0.6662

F-statistic: 446.2 on 10 and 2221 DF, p-value: < 2.2e-16

-summary(lm_model_s2)

```
> summary(lm_model_s2)
```

```
Call:
lm(formula = Log_Total_Spending ~ Income + age + Marital_Status +
    Recency + NumWebVisitsMonth + TotalCampaignsAccepted + TotalChildren,
    data = marketing_df_cleaned)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-9.2793 -0.4591  0.1049  0.5612  5.0242
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.190e+00  1.478e-01  14.817  < 2e-16 ***
Income          5.387e-05  1.206e-06  44.682  < 2e-16 ***
age             6.947e-03  1.649e-03   4.214  2.61e-05 ***
Marital_StatusMarried  8.662e-02  6.376e-02   1.359  0.174432
Marital_StatusSingle  6.744e-02  6.920e-02   0.975  0.329848
Marital_StatusTogether 7.061e-02  6.687e-02   1.056  0.291077
Marital_Statuswidow   1.725e-01  1.137e-01   1.517  0.129420
Recency         1.184e-03  6.305e-04   1.878  0.060530 .
NumWebVisitsMonth    9.007e-02  1.039e-02   8.667  < 2e-16 ***
TotalCampaignsAccepted 8.416e-02  2.250e-02   3.740  0.000189 ***
TotalChildren     -4.361e-01  2.766e-02 -15.767  < 2e-16 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.8575 on 2221 degrees of freedom
Multiple R-squared:  0.6674,    Adjusted R-squared:  0.6659
F-statistic: 445.7 on 10 and 2221 DF,  p-value: < 2.2e-16
```

※ 주요 R코드

-변수 정의

```
marketing_df$age = 2025 - marketing_df$Year_Birth
```

```
marketing_df$TotalChildren = marketing_df$Kidhome + marketing_df$Teenhome
```

```
marketing_df = marketing_df %>% mutate(Total_Spending = MntWines + MntFruits +  
MntMeatProducts+MntFishProducts+MntSweetProducts+MntGoldProds)
```

```
marketing_df = marketing_df %>% mutate(TotalCampaignsAccepted =  
AcceptedCmp1+AcceptedCmp2+AcceptedCmp3+AcceptedCmp4+AcceptedCmp5+Respon  
se)
```

```
marketing_df$Education=as.factor(marketing_df$Education)
```

```
marketing_df$Marital_Status=as.factor(marketing_df$Marital_Status)
```

```
marketing_df <- marketing_df[!marketing_df$Marital_Status %in% c("Absurd",  
"YOLO"), ]
```

```
marketing_df$Marital_Status[marketing_df$Marital_Status == "Alone"] <- "Single"
```

```
marketing_df <- marketing_df[marketing_df$age < 100, ]
```

-플롯

```
# Total_Spending 히스토그램
```

```
library(ggplot2)
```

```
ggplot(marketing_df, aes(x = Total_Spending)) +
```

```
geom_histogram(binwidth = 50, fill = "skyblue", color = "black", alpha = 0.8) +
```

```
labs(title = "총 소비액 분포", x = "총 소비액", y = "고객 수") +
```

```
theme_minimal() +
```

```
theme(plot.title = element_text(hjust = 0.5, face = "bold")) # 제목 중앙 정렬 및 볼드체
```

```
# Income 히스토그램
```

```
ggplot(marketing_df, aes(x = Income)) +
```

```
geom_histogram(binwidth = 5000, fill = "lightgreen", color = "black", alpha = 0.8) +
```

```
labs(title = "소득 분포", x = "소득", y = "고객 수") +
```

```
theme_minimal() +
```

```
theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

```
# TotalCampaignsAccepted 막대 그래프
```

```
ggplot(marketing_df, aes(x = as.factor(TotalCampaignsAccepted))) +
```

```

geom_bar(fill = "lightcoral", color = "black", alpha = 0.8) +
labs(title = "총 수락 캠페인 수 분포", x = "총 수락 캠페인 수", y = "고객 수") +
theme_minimal() +
theme(plot.title = element_text(hjust = 0.5, face = "bold"))
# Age 히스토그램
ggplot(marketing_df, aes(x = age)) +
geom_histogram(binwidth = 5, fill = "lightblue", color = "black", alpha = 0.8) +
labs(title = "나이 분포", x = "나이", y = "고객 수") +
theme_minimal() +
theme(plot.title = element_text(hjust = 0.5, face = "bold"))
# TotalChildren 막대 그래프 (자녀 수는 정수형이므로 막대 그래프가 적합)
ggplot(marketing_df, aes(x = as.factor(TotalChildren))) +
geom_bar(fill = "pink", color = "black", alpha = 0.8) +
labs(title = "총 자녀 수 분포", x = "총 자녀 수", y = "고객 수") +
theme_minimal() +
theme(plot.title = element_text(hjust = 0.5, face = "bold"))
# Education 막대 그래프
ggplot(marketing_df, aes(x = Education, fill = Education)) +
geom_bar(color = "black", alpha = 0.8) +
labs(title = "교육 수준 분포", x = "교육 수준", y = "고객 수") +
theme_minimal() +
theme(plot.title = element_text(hjust = 0.5, face = "bold"))
# Marital_Status 막대 그래프
ggplot(marketing_df, aes(x = Marital_Status, fill = Marital_Status)) +
geom_bar(color = "black", alpha = 0.8) +
labs(title = "결혼 여부 분포", x = "결혼 여부", y = "고객 수") +
theme_minimal() +
theme(plot.title = element_text(hjust = 0.5, face = "bold"))

# 1. Income vs Total_Spending 산점도
plot(marketing_df$Income, marketing_df$Total_Spending,
main = "소득과 총 소비액 관계",
xlab = "소득", ylab = "총 소비액",
col = "darkblue", pch = 16, cex = 0.8)
# 2. Age vs Total_Spending 산점도
plot(marketing_df$age, marketing_df$Total_Spending,
main = "나이와 총 소비액 관계",
xlab = "나이", ylab = "총 소비액",
col = "darkgreen", pch = 16, cex = 0.8)
# 3. TotalCampaignsAccepted vs Total_Spending 상자 그림
boxplot(marketing_df$Total_Spending

```

~

```

as.factor(marketing_df$TotalCampaignsAccepted),
main = "캠페인 수락 수에 따른 소비액",
xlab = "총 수락 캠페인 수", ylab = "총 소비액",
col = "lightcoral", border = "black")
# 4. TotalChildren vs Total_Spending 상자 그림
boxplot(marketing_df$Total_Spending ~ as.factor(marketing_df$TotalChildren),
main = "총 자녀 수에 따른 소비액",
xlab = "총 자녀 수", ylab = "총 소비액",
col = "pink", border = "black")
# 5. Education vs Total_Spending 상자 그림
boxplot(marketing_df$Total_Spending ~ marketing_df$Education,
main = "교육 수준별 총 소비액",
xlab = "교육 수준", ylab = "총 소비액",
col = c("yellow", "orange", "red", "purple", "brown"),
border = "black")
# 6. Marital_Status vs Total_Spending 상자 그림
boxplot(marketing_df$Total_Spending ~ marketing_df$Marital_Status,
main = "결혼 여부별 총 소비액",
xlab = "결혼 여부", ylab = "총 소비액",
col = rainbow(length(unique(marketing_df$Marital_Status))),
border = "black")

```

-모델 구축 및 진단

```

marketing_df$Log_Total_Spending <- log(marketing_df$Total_Spending)

lm_model <- lm(Log_Total_Spending ~ Income + age + Education + Marital_Status +
Recency + NumWebVisitsMonth + TotalCampaignsAccepted + TotalChildren,
data = marketing_df)

vif_values <- vif(lm_model)

plot(lm_model)

marketing_df_cleaned <- marketing_df[-2227, ]

lm_model_cleaned <- lm(Log_Total_Spending ~ Income + age + Education +
Marital_Status + Recency + NumWebVisitsMonth + TotalCampaignsAccepted +
TotalChildren, data = marketing_df_cleaned)

plot(lm_model_cleaned)

```

```

cooks_d <- cooks.distance(lm_model_cleaned)
plot(cooks_d, pch="*", cex=2, main="Cooks distance for lm_model_cleaned")
abline(h = 4/length(cooks_d), col="red", lty=2)
text(x=1:length(cooks_d), y=cooks_d, labels=ifelse(cooks_d > 4/length(cooks_d),
names(cooks_d), ""), col="red", pos=3)

```

```

lm_model_s1 <- lm(Log_Total_Spending ~ Income + age + Education + Recency +
NumWebVisitsMonth + TotalCampaignsAccepted + TotalChildren, data =
marketing_df_cleaned)

```

```

lm_model_s2 <- lm(Log_Total_Spending ~ Income + age + Marital_Status + Recency
+ NumWebVisitsMonth + TotalCampaignsAccepted + TotalChildren, data =
marketing_df_cleaned)

```

```

lm_model_s3 <- lm(Log_Total_Spending ~ Income + age + Recency +
NumWebVisitsMonth + TotalCampaignsAccepted + TotalChildren, data =
marketing_df_cleaned)

```